

CallVerse — Quality Analyst

Lot qualité et XAI : grille, LLM-as-judge, annotation, accord inter-juges

Phase 1 — Fondations et contrats

Mission du lot

Ce que tu construis

1. La grille d'évaluation

2. Le LLM-as-judge

3. La détection de non-sourçage

4. Le NLP complémentaire

La validation — la partie qui rapporte le plus de points

Explicabilité (XAI)

Modèle de données

Plan de travail — semaine 1

Pièges à éviter

Critères de sortie du lot

Mission du lot

Évaluer automatiquement **100 % des interactions** du centre, produire un score explicable, et prouver que ce score est fiable.

Dans un vrai centre, un superviseur écoute manuellement une fraction marginale des conversations. Le reste n'est jamais évalué, et les problèmes récurrents ne sont détectés que quand un client se plaint. C'est le problème que ce lot résout.

Tu peux démarrer le jour 1 sans dépendre de personne : tu écris toi-même les premières conversations de test.

Ce que tu construis

1. La grille d'évaluation

Six critères pondérés, stockés dans la table `quality_criterion` et configurables depuis le back-office :

Critère	Ce qu'il mesure
Pertinence	La réponse traite-t-elle la demande posée ?
Exactitude	L'information donnée est-elle correcte ?
Conformité	La procédure a-t-elle été respectée ?
Communication	Clarté, structure, absence de jargon
Empathie	Reconnaissance de la situation du client
Résolution	Le problème est-il effectivement réglé ?

Les pondérations doivent être **justifiées**, pas choisies au hasard. Documente ton raisonnement, le jury le demandera.

2. Le LLM-as-judge

Un LLM évalue chaque conversation selon la grille, avec une **sortie JSON contrainte** :

```

POST /ai/quality/evaluate
{
  "conversation_id": "uuid",
  "messages": [{"sender": "CUSTOMER|ADVISOR", "content": "..."}],
  "sources_used": [{"kb_article_id": "uuid"}],
  "resolved": true
}
-> {
  "global_score": 7.8,
  "scores": {
    "relevance": 8, "accuracy": 9, "compliance": 7,
    "communication": 8, "empathy": 6, "resolution": 9
  },
  "explanation": "string",
  "evidence": [
    {"criterion": "empathy", "message_index": 3, "excerpt": "..."}
  ],
  "flags": {"unsourced_claims": 2},
  "recommendations": ["string"]
}

```

Le champ `evidence` est ce qui rend le score explicable : il pointe la phrase exacte qui a motivé chaque note. C'est ce qu'affiche le drill-down du dashboard qualité.

3. La détection de non-sourçage

Vérifier que chaque affirmation factuelle de la réponse est couverte par un des documents listés dans `sources`. Une affirmation non couverte est une hallucination potentielle, signalée dans `flags.unsourced_claims`.

C'est une métrique que le lot Customer Advisor consomme directement. Coordonne-toi avec cette personne sur le format.

4. Le NLP complémentaire

- **Classification d'intention** : facturation, technique, commercial, résiliation. Datasets publics de support client disponibles pour la validation.
- **Analyse de sentiment** sur la trajectoire de la conversation : le client finit-il moins énervé qu'il n'a commencé ?

La validation — la partie qui rapporte le plus de points

Un score automatique sans validation n'est qu'une opinion de machine. La démarche qui transforme ce lot en résultat scientifique :

1. **Annoter à la main 30 à 50 conversations** selon la même grille. Idéalement par deux personnes différentes, pour mesurer aussi l'accord entre humains.
2. **Faire évaluer les mêmes conversations par le LLM-as-judge.**
3. **Mesurer l'accord** : corrélation de Pearson sur le score global, et **Cohen's kappa** sur les notes par critère.
4. **Cible : kappa supérieur à 0,6** (accord substantiel). Si tu es en dessous, c'est un résultat aussi — tu analyses pourquoi et sur quels critères.

Les deux jeux d'évaluation cohabitent dans la table `quality_evaluation` grâce au champ `evaluator` valant `AI` ou `HUMAN`. Le calcul de l'accord se fait par une simple jointure.

Test de robustesse recommandé : injecte volontairement des erreurs dans quelques conversations (information fausse, procédure non respectée, ton inapproprié) et vérifie que le juge les détecte. Ça mesure la sensibilité de ton évaluateur, et c'est rarement fait.

Explicabilité (XAI)

Ce lot porte une grande partie de la dimension XAI du projet :

- Chaque score est accompagné du détail par critère.
- Chaque critère est justifié par un extrait précis de la conversation.
- Les recommandations d'amélioration sont générées par conseiller, agrégées sur ses conversations.

Le dashboard qualité (construit par le lot frontend) affiche tout cela. Fournis les données dans le format attendu, il ne devra rien recalculer.

Modèle de données

Deux tables te concernent, détaillées dans le document 03 :

```
quality_criterion (id, code, label, weight, active)
quality_evaluation (id, conversation_id, global_score, scores JSONB,
                  explanation, flags JSONB, evaluator, created_at)
```

Les scores par critère sont en JSONB : leur structure suit la grille, qui est configurable. Ne crée pas une colonne par critère.

Plan de travail — semaine 1

Jour	Tâche
1	Grille d'évaluation définie, 6 critères pondérés et justifiés
2	10 conversations de test écrites à la main (bonnes, moyennes, mauvaises)
3	Prompt du LLM-as-judge, sortie JSON contrainte
4	POST /ai/quality/evaluate conforme au contrat, même sur données locales
5	Première comparaison juge automatique contre annotation manuelle

Pièges à éviter

1. **Livrer un score sans validation humaine.** C'est ce qui distingue un projet de Data Science d'une fonctionnalité gadget.
2. **Une colonne SQL par critère.** La grille est configurable, le JSONB est fait pour ça.
3. **Omettre evidence.** Sans les extraits, le score n'est pas explicable et la partie XAI disparaît.
4. **Annoter seul et sans grille écrite.** L'annotation doit suivre exactement la même grille que le juge, sinon la comparaison ne veut rien dire.
5. **Attendre que des conversations existent.** Écris-en toi-même, c'est plus rapide et tu contrôles les cas que tu veux tester.

Critères de sortie du lot

- ☐ Grille de 6 critères définie, pondérations justifiées par écrit
- ☐ 10 conversations de test écrites, couvrant bon / moyen / mauvais
- ☐ Prompt du juge rédigé, sortie JSON contrainte et validée
- ☐ POST /ai/quality/evaluate conforme au contrat
- ☐ Première mesure d'accord juge / humain sur au moins 10 conversations
- ☐ Procédure d'annotation documentée pour la suite du projet